

RELATÓRIO ESTRATÉGICO

Roadmap AI Engineer 2026

Mercado, Stack, Mapa de Estudos e Plano Executivo

Preparado para

Pablo Costa

Desenvolvedor · AI Automation Engineer · João Paese, Paraíba (Brasil)

Documento gerado em 25/05/2026

Baseado em dados públicos de mercado 2025–2026 (LinkedIn, BLS, ManpowerGroup, WEF, Stanford AI Index, Howdy, Lemon.io, agentic-engineering-jobs.com)

Sumário

1. Sumário executivo	3
2. Mercado e demanda por AI Engineers	4
3. Salários 2026: Brasil remoto para o exterior	7
4. Stack tecnológica em demanda	9
5. Mapa de estudos — 7 fases sequenciais	12
6. Python para entry-level (deep dive)	14
7. Plano de 90 dias com projetos flagship	17
8. Plataformas, posicionamento e anti-padrões	19
9. Recursos permanentes (blogs, livros, cursos)	21
10. Fontes consultadas	23

1. Sumário executivo

Contexto

Este relatório consolida a análise estratégica produzida ao longo de uma sequência de discussões sobre posicionamento de carreira em AI Engineering. O objetivo é responder, com dados de mercado 2026, às três perguntas centrais que orientam a transição: **(a) qual o tamanho real da demanda?**, **(b) qual a stack técnica que está sendo efetivamente paga?**, e **(c) qual o caminho de estudos mais curto e direto para chegar a uma vaga mid-level remota internacional?**

Perfil-alvo

Pablo Costa, desenvolvedor brasileiro com base em João Paese (PB), B.Tech em Sistemas para Internet (UNIESP, conclusão prevista para julho de 2026), inglês fluente (4 anos morando na Austrália), stack principal em Java/Spring Boot, Python (intermediário), PostgreSQL, Docker, n8n, OpenAI API e WhatsApp automation. Possui projeto flagship em produção (DentBot, recepcionista AI via WhatsApp para Dental Studio Odontologia Especializada) e múltiplos clientes ativos em automação.

Recomendação central

O cenário 2026 combina três fatores favoráveis simultaneamente: (1) **AI Engineer é a vaga #1 que mais cresce nos EUA** segundo o LinkedIn Jobs on the Rise 2026, com 143% de crescimento ano a ano; (2) o **gap global entre demanda e oferta é de 3,2:1** (1,6 milhão de vagas abertas vs. 518 mil candidatos qualificados); e (3) os **salários cresceram 38% ano a ano** com prêmio de 67% sobre vagas tradicionais de software. A janela está aberta exatamente porque o mercado é jovem demais para exigir 10 anos de experiência.

A trajetória recomendada para Pablo é **não competir como júnior genérico**, mas posicionar-se como *AI Engineer com projeto em produção*. O DentBot já cumpre o requisito de "proof of work" que separa candidatos sérios de tutoriais. O caminho consiste em fechar 14 semanas de estudo dirigido (mapa detalhado na Seção 5) somadas a 12 semanas de execução de projetos flagship (Seção 7), totalizando aproximadamente 6 meses para chegar a uma faixa-alvo realista de US\$ 50.000 a US\$ 80.000 por ano em vagas full-time remotas, ou US\$ 30 a US\$ 60 por hora em freelance especializado.

Metas mensuráveis em 6 meses

- 3 repositórios públicos com READMEs profissionais em inglês demonstrando RAG production-grade, sistema agentic com MCP, e voice AI integrado a WhatsApp.
- 1 servidor MCP publicado no GitHub (diferencial raro — poucos candidatos têm).
- 8 a 12 posts técnicos no LinkedIn (build in public) gerando inbound de recruiters.
- 30+ aplicações em 4 plataformas curadas (Lemon.io, Wellfound, Arc.dev, Revelo) — não dispersar.
- Pelo menos 3 entrevistas técnicas realizadas (dado é dado, mesmo em caso de rejeição).
- 1 oferta full-time mid-level ou contrato freelance estável acima de 25h/semana.

2. Mercado e demanda por AI Engineers

O macro: investimento e criação de vagas

O investimento global em inteligência artificial atingiu patamares sem precedentes em 2025 e segue acelerando em 2026. Segundo dados consolidados do Stanford AI Index, Menlo Ventures e Gartner:

- Gasto mundial com IA projetado em **US\$ 2,52 trilhões em 2026**, alta de 44% ano a ano (Gartner).
- Investimentos em IA atingiram **US\$ 225,8 bilhões em 2025**, recorde histórico (Stanford AI Index).
- Empresas representando IA captaram **48% do funding total de equity em 2025**, embora sejam apenas 23% dos deals.
- Gasto empresarial em IA passou de US\$ 1,7 bi para **US\$ 37 bi entre 2023 e 2025** — multiplicação por 21 em dois anos (Menlo Ventures).
- Dados do LinkedIn citados pelo World Economic Forum apontam **1,3 milhão de novas vagas** em funções como AI Engineer, Forward-Deployed Engineer e Data Annotator, somadas a **600 mil novas vagas em data centers**.

AI Engineer = a vaga #1 que mais cresce

O LinkedIn Jobs on the Rise 2026 ranqueou AI Engineer como o **título com maior crescimento nos Estados Unidos**. Vagas subiram 143% ano a ano em 2025. Entre 2023 e 2025, foram adicionadas **639 mil vagas relacionadas a IA**, das quais **75 mil são especificamente AI Engineer**.

Para o segundo ano consecutivo, AI Engineer é também a vaga que mais cresce **entre jovens trabalhadores**, segundo a mesma plataforma. Os dados de perfil dos contratados:

Indicador	Valor
Skills mais comuns	LangChain, RAG, PyTorch
Anos medianos de experiência prévia	3,7 anos
Cargos de origem (top 3)	Software Engineer, Data Scientist, Full Stack Engineer
Setores top	Technology, IT Services, Business Consulting
Concentração geográfica	San Francisco, NYC, Dallas
Disponibilidade remoto/híbrido	26,2% remoto + 27,1% híbrido = 53,3%

Fonte: LinkedIn Jobs on the Rise 2026 Report

O gap demanda x oferta é estrutural

O desequilíbrio entre vagas abertas e profissionais qualificados é o dado mais relevante para entender a posição de barganha do candidato em 2026:

- **Razão demanda:oferta global de 3,2:1** em IA (Second Talent, 2026).
- **1,6 milhão de vagas abertas** em IA contra apenas **518 mil candidatos qualificados**.
- **Salários de IA pagam 67% acima** de vagas tradicionais de software, com crescimento de 38% ano a ano em todos os níveis de senioridade.
- Pesquisa ManpowerGroup com 39.000 empregadores em 41 países (2026): **habilidades de IA tornaram-se as mais difíceis de preencher globalmente**, ultrapassando engenharia tradicional e IT pela primeira vez.
- AI Model & Application Development (20%) e AI Literacy (19%) lideram o ranking global de skills hard-to-find.

Subáreas com crescimento mais íngreme

Subárea	Crescimento	Fonte
Vagas mencionando 'Agentic AI'	+985% (2023→2024)	McKinsey
Prompt Engineering	+135,8% ano a ano	PromptLayer
AI Chatbot Development	+71% ano a ano	Upwork
AI Governance	+150%	AI Workforce Consortium
AI Ethics	+125%	AI Workforce Consortium

Observação: Agentic AI e prompt engineering estão no centro do mapa de estudos proposto (Seção 5). Não é coincidência — é alinhamento com a curva mais íngreme da demanda.

Projeções oficiais de longo prazo

O U.S. Bureau of Labor Statistics projeta que **Computer and Information Research Scientists** — categoria que inclui AI Engineers — crescerá **23% entre 2023 e 2033**, muito acima da média de todas as ocupações. Para Software Developers em geral, a projeção é de 15% no mesmo período.

Ou seja: **AI Engineer cresce aproximadamente 1,5x mais rápido que software dev tradicional**. O World Economic Forum (Future of Jobs Report 2025) classifica IA e Big Data como as habilidades de crescimento mais acelerado até 2030.

Sete das dez funções de ICT (Information and Communications Technology) que mais crescem são relacionadas a IA, segundo o AI Workforce Consortium liderado pela Cisco: AI/ML Engineer, AI Risk and Governance Specialist e NLP Engineer estão entre as principais.

O contraponto honesto: entry-level genérico

É importante apresentar o lado adverso. **O entry-level geral está apertado**, mesmo com AI Engineer em alta:

- Contratações entry-level nos EUA **caíram 6%** entre dezembro de 2025 e fevereiro de 2026, comparado ao mesmo período do ano anterior (LinkedIn).
- Vagas chamadas "entry-level" frequentemente exigem 2 a 3 anos de experiência prévia — o paradoxo "precisa do emprego para conseguir o emprego".
- Tarefas que historicamente serviam como porta de entrada (coding básico, análise junior, suporte) estão sendo absorvidas por ferramentas de IA.
- ZipRecruiter 2026 Annual Grad Report: graduados com experiência de trabalho durante a faculdade são contratados a uma taxa de **81,6%**, contra **40,7%** dos que não têm — diferença de mais de 2:1.
- Citação direta de Tomas Pfister (Head of AI Research, Google Cloud): *"Definitely looking for people that have actually built something already — something more serious beyond just a simple toy project."*

Implicação prática para o caso Pablo

A leitura cruzada dos dois movimentos (demanda absurda em IA + entry-level genérico apertado) leva a quatro conclusões operacionais:

- 1. AI Engineer não é entry-level commodity.** Implicitamente significa "júnior com 1 ou 2 projetos production-grade no portfolio". Pablo já tem o DentBot — o study map fecha o restante.
- 2. O gap 3,2:1 não fecha em 2 a 3 anos.** Universidades não treinam AI Engineer no ritmo do mercado. A janela permanece aberta.
- 3. Posicionamento importa mais que título.** Não competir como "júnior dev". Competir como "AI Engineer com projeto em produção atendendo cliente real, inglês fluente, 4 anos no exterior". Categoria

distinta, mercado distinto.

4. Timing é raro. Mediana de 3,7 anos de experiência prévia para AI Engineer reflete a juventude do campo. Pouco gatekeeping de "10 anos de XP exigidos" — privilégio temporário desta janela específica.

3. Salários 2026: Brasil remoto para o exterior

Visão consolidada

As faixas abaixo refletem o estado do mercado em maio de 2026, agregadas de Howdy, South, Mismo, Lemon.io, agentic-engineering-jobs.com, Numerando, Robert Half e ManpowerGroup. Todas as cifras estão em USD/ano salvo indicação em contrário.

Mercado	Júnior	Mid	Sênior
Brasil — empresas locais (CLT)	R\$ 36–66 mil	R\$ 78–144 mil	R\$ 156–360 mil
Brasil → US remote (general dev)	US\$ 20–50K	US\$ 50–80K	US\$ 75–120K
AI Engineer — Brasil/LATAM	US\$ 33–44K	US\$ 42–72K	US\$ 66–99K
AI Engineer — Lemon.io/agentic listings	—	US\$ 70–120K	US\$ 130–300K
n8n Developer (US full-time)	—	US\$ 60–90K	US\$ 110–140K
Europa (junior backend remote)	€55–75K	€75–110K	€100–160K

Brasil — empresas locais

Faixas observadas em 2026 para desenvolvedores júnior CLT: **R\$ 3.000 a R\$ 4.000 por mês** em empresas pequenas e regiões fora dos hubs (SP, Floripa, BH); **R\$ 4.000 a R\$ 6.000 por mês** em startups e capitais. PJ tipicamente paga 30% a 50% a mais para compensar ausência de 13º, férias e FGTS. Em IA especificamente no Brasil, profissionais com Python + frameworks podem ultrapassar R\$ 20.000/mês mesmo em empresas nacionais.

Brasil → US remote: a faixa que importa

Empresas norte-americanas raramente contratam "júnior puro" remoto fora dos EUA. Preferem mid-level (2 a 4 anos), onde a arbitragem de custo compensa o overhead de cross-border. Faixas de hourly rate para Brasil, segundo Howdy 2026:

- **Júnior:** US\$ 20 a 40/hora (US\$ 40k–80k/ano em full-time).
- **Mid-level:** US\$ 35 a 70/hora (US\$ 70k–140k/ano).
- **Sênior:** US\$ 65 a 100/hora (US\$ 130k–200k+/ano).

O Brasil ocupa o miolo da faixa LATAM — geralmente acima de Colômbia e Argentina, abaixo de Chile. Aumentos salariais previstos para 2026 em LATAM: 5,3% no Brasil, 5,4% no México, 6% na Colômbia — todos acima do projetado nos EUA (3,7%).

AI Engineer especificamente

Dados Jobby (fevereiro 2026) e Qubit Labs para AI Engineer no Brasil:

- **Junior level:** US\$ 33.105 a US\$ 44.140/ano.
- **Senior level:** US\$ 66.210 a US\$ 99.315/ano.
- **Média geral Brasil:** US\$ 55.175/ano.
- **Média LATAM:** US\$ 40.800/ano.

South Hire informa que mid-level AI engineer no Brasil/Argentina ganha US\$ 3.500 a US\$ 6.000/mês (US\$ 42K a US\$ 72K/ano). Especialistas em IA têm previsão de **aumento de 12% a 18% em 2026** em LATAM, superando o já alto crescimento geral.

*Mercado de "Dois Tiers de Python" em 2026: dev Python padrão ganha em torno de US\$ 44k/ano. Engenheiro que arquiteta **Agentic Workflows** ou otimiza pipelines RAG ganha substancialmente mais.*

Esse é o posicionamento-alvo.

n8n e Automation — o nicho do Pablo

Dados ZipRecruiter (maio 2026): n8n developer nos EUA recebe em média US\$ 52,84/hora, com faixa de US\$ 40,38 a US\$ 64,66/hora. Full-time nos EUA: US\$ 110.000 a US\$ 140.000/ano. Nearshore (incluindo Brasil): US\$ 35.000 a US\$ 60.000/ano, 50% a 60% abaixo do US rate mas ainda muito acima do mercado local.

Listings agentic AI com tag n8n em agentic-engineering-jobs.com (abril 2026): mediana US\$ 163.400, faixa US\$ 30.000 a US\$ 300.000 — mas predominantemente vagas mid e sênior.

Europa: viável mas com fricção

Europa contrata mais dentro da própria UE por compliance tributária. Para brasileiros, melhor janela é em UK, Holanda, Portugal e Espanha, onde políticas remote-global são mais abertas. Faixas de referência:

- **Junior software engineer remoto na Europa:** €65.154/ano (Remote Rocketship, baseado em 175 vagas).
- **Junior backend engineer remoto na Europa:** €75.414/ano (513 vagas).
- **Europa Ocidental geral:** US\$ 73K a US\$ 120K/ano.
- **Europa Oriental:** US\$ 27,6K a US\$ 42K/ano.
- **Premium AI Engineer na Europa:** +12% sobre eng. de software geral em individual contributor track (Ravio).

Faixa realista para Pablo (mid-2026)

Com o DentBot em produção, DentBot SaaS em desenvolvimento, inglês fluente e os 3 projetos do plano de 90 dias entregues, as faixas plausíveis em 6 meses:

Modalidade	Faixa inicial	Faixa otimizada
Freelance n8n/AI Automation	US\$ 30–40/hora	US\$ 50–70/hora
Full-time "AI Automation Engineer" júnior+	US\$ 40–60K/ano	US\$ 60–80K/ano
Full-time mid-level AI Engineer	US\$ 50–70K/ano	US\$ 80–120K/ano

Onde não mirar agora: vagas que exigem ML training, fine-tuning sério, MLOps avançado em produção, ou conhecimento matemático profundo de ML. Não é o ground técnico atual. Mire em: AI Automation Engineer, LLM Integration Engineer, Workflow Automation Engineer, AI Implementation Engineer e Solutions Engineer (AI).

4. Stack tecnológica em demanda

Frequência real em job postings (2026)

365 Data Science analisou 1.000 vagas de AI Engineer em 2026. agentive-engineering-jobs.com mantém base de 534 vagas ativas específicas de agentive AI. Combinando os dois datasets:

Skill / Tecnologia	% de vagas que pedem
Python	71%
AWS	32,9%
Azure	26%
NLP (geral)	19,7%
SQL	17,1%
LangChain (em listings agentive)	34,3%
Java (vagas enterprise AI)	22%

Stack core (toda vaga pede)

Python — não "intermediário", sólido

- Type hints completos (TypedDict, Protocol, Generic).
- `async/await`, `asyncio`, `async context managers`.
- Pydantic v2 (validation, serialization, settings).
- Decorators, context managers, generators.
- `pytest` com fixtures, `parametrize`, `mocking`.
- Structured logging (`structlog` ou `logging` formatado).
- Error handling explícito (custom exceptions, chaining).

Backend API

- **FastAPI** — padrão de fato em vagas AI Engineer.
- Pydantic v2 para validação de I/O.
- Streaming responses (SSE/WebSockets) — table stakes para LLMs.
- Async endpoints, background tasks, dependency injection.

LLM SDKs (pelo menos 2)

- **OpenAI** e **Anthropic** — obrigatórios.
- Google Gemini, Cohere — diferencial.
- Tool/function calling, structured outputs, streaming.

Frameworks de orquestração

- **LangChain + LangGraph** — primeiro lugar em volume (34,3% das vagas agentive).
- LlamaIndex — comum como camada de retrieval.
- Recomendação: aprender LangChain Expression Language (LCEL), mas também praticar pipelines diretamente contra APIs sem framework. Over-reliance em framework gera red flag em entrevista.

Vector Databases (pelo menos 1)

- Opções comuns: Pinecone, FAISS, pgvector, Weaviate, Qdrant, Chroma.

- **Recomendação para Pablo:** pgvector (já domina Postgres) como primário; Pinecone como segundo (padrão SaaS US).

RAG — o assunto mais pedido

- Chunking strategies (fixed, recursive, semantic).
- Embeddings (text-embedding-3, voyage, cohere).
- **Hybrid search:** dense (vector) + sparse (BM25) + RRF (Reciprocal Rank Fusion).
- **Reranking** com Cross-Encoders (Cohere Rerank, BGE).
- **HyDE** (Hypothetical Document Embeddings).
- Query transformation e rewriting.

Cloud e Deploy

- **AWS** em primeiro (32,9% das vagas) — Lambda, ECS, Bedrock, S3.
- Azure se mirar enterprise.
- Serverless: FastAPI + Modal / AWS Lambda / Vercel edge.
- Docker (Pablo já domina).

Stack premium (puxa salário)

Evaluation e Observability — diferencial enorme

- **LangSmith** (time LangChain) — padrão em listings.
- Phoenix (Arize) — open source.
- Helicone — proxy-based.
- Custom eval harnesses com LLM-as-judge.
- Métricas: groundedness, relevance, citation accuracy.

"It works" sem métrica de eval é desqualificação automática em entrevista mid-level. Métricas em README valem tanto quanto o código.

Agentic e Multi-agent systems

- LangGraph (state machines, plan-execute-critique loops).
- CrewAI, AutoGen (Microsoft) — alternativas.
- **MCP (Model Context Protocol)** — padrão emergente. Hit 97 milhões de downloads/mês em fev/2026. Suportado por Anthropic, OpenAI, Google e Microsoft. **Item de maior ROI no mapa de estudos.**

Voice AI (nicho que paga muito)

- Whisper (STT — Speech-to-Text).
- ElevenLabs ou OpenAI TTS (Text-to-Speech).
- WebRTC para real-time.
- Listings Lemon.io recentes: US\$ 90/hora para Senior AI Engineer com FastAPI + WebRTC + Whisper + ElevenLabs.

O que NÃO chasear agora

Estes itens aparecem em listas genéricas, mas são raros em vagas AI Engineer aplicado e tomam tempo desproporcional ao retorno:

- Fine-tuning e treinamento de modelo — exige matemática, PhD ou anos de ML.
- Kubernetes avançado — Lambda/Modal cobrem 95% dos casos.
- PyTorch/TensorFlow deep learning — não é necessário para AI Engineer aplicado.
- MLOps complexo (Kubeflow, MLflow avançado).

- MATLAB, R, C++ — citados em listas genéricas, raríssimos em vagas aplicadas.

Stack-alvo realista (resumo)

Com 10 itens dominados e demonstrados em 1-2 projetos no GitHub, Pablo entra na faixa US\$ 50–80K/ano remoto. Adicionar voice AI ou agentic systems com eval rigoroso eleva para US\$ 80–120K.

```
Python (avançado) + FastAPI + LangChain/LangGraph +  
pgvector/Pinecone + RAG hybrid + LangSmith +  
Docker + AWS Lambda + OpenAI/Anthropic APIs + MCP
```

5. Mapa de estudos — 7 fases sequenciais

Visão geral

Currículo opinativo, sequencial, com aproximadamente 210 horas totais distribuídas em 14 semanas (~15h/semana). Cada fase tem um *check de domínio* prático — um build pequeno que comprova entendimento, não apenas consumo passivo de conteúdo. Regra dura: 70% mãos na massa, 30% teoria.

Fase	Tema	Semanas	Horas
1	Python sólido + Backend (FastAPI, Postgres)	1–3	~45h
2	LLM APIs sem framework (OpenAI, Anthropic, Prompt Eng)	4–5	~30h
3	RAG (embeddings, vector DBs, hybrid, eval)	6–8	~45h
4	Orquestração (LangChain LCEL, LangGraph)	9–10	~30h
5	MCP (Model Context Protocol)	11	~15h
6	Eval e Observability (LangSmith, LLM-as-judge)	12	~15h
7	Cloud e Deploy (Docker, AWS Lambda, Modal, CI/CD)	13–14	~30h

Princípios estruturantes

- 1. Primitivos antes de abstração.** SDKs puros na Fase 2 antes de LangChain na Fase 4. Quem pula esta sequência não consegue debugar quando o framework falha.
- 2. Check de domínio em cada bloco.** Sem o build prático, a fase não é considerada concluída. Tutorial assistido não vale.
- 3. Recursos curados, não exaustivos.** 2 a 3 fontes por bloco. Acumular cursos é procrastinação disfarçada.
- 4. Anti-PyTorch/ML clássico.** Zero fine-tuning, zero matemática pesada, zero Kubernetes avançado. Não é o target atual.

Fase 1 — Python sólido e Backend (3 semanas)

Detalhamento completo na Seção 6 (deep dive de Python para entry-level AI Engineer). Inclui FastAPI com streaming SSE, Postgres avançado (indexes, JSONB, full-text search) e estruturação moderna de projeto com uv, ruff e mypy.

Check de domínio: refactor de um projeto pessoal (DentBot ou Pioneira) aplicando 100% type hints, ruff sem warnings, mypy sem errors, pytest cobrindo o fluxo principal e structured logging substituindo prints.

Fase 2 — LLM APIs fundamentais (2 semanas)

Regra dura: nenhum framework nesta fase. Apenas SDK puro do OpenAI e Anthropic. Tool calling, structured outputs, streaming e prompt engineering aplicado. Refactor do chatbot para alternar entre os dois providers via env var.

Recursos: OpenAI Cookbook (github.com/openai/openai-cookbook), Anthropic Cookbook, Anthropic's Prompt Engineering Interactive Tutorial (Jupyter notebooks, gratuito).

Fase 3 — RAG (3 semanas)

O tópico mais pedido em vagas de AI Engineer. Cobertura completa: embeddings, vector databases (pgvector como primário), RAG básico, então RAG avançado (hybrid search com BM25 + RRF, reranking com Cross-Encoders, query transformation, HyDE, parent-child chunking). Encerra com eval rigoroso usando métricas de groundedness e relevance.

Recursos: Anthropic's Contextual Retrieval blog post (leitura obrigatória), Pinecone Learning Center, Hamel Husain's eval posts, Ragas docs.

Fase 4 — Orquestração (2 semanas)

LangChain LCEL (Runnables, chains, tools, output parsers) + LangGraph (state graphs, conditional flow, multi-agent patterns). DeepLearning.AI tem dois cursos curtos gratuitos que cobrem exatamente este conteúdo: "LangChain for LLM Application Development" (Harrison Chase) e "AI Agents in LangGraph".

Fase 5 — MCP (1 semana)

Item de maior ROI do mapa. Padrão emergente que quase ninguém tem no portfolio. O check de domínio é publicar um MCP server no GitHub (sugestão: "devdocs-mcp" que faz Q&A sobre documentação técnica). Recursos: modelcontextprotocol.io (oficial), Anthropic MCP introduction, FastMCP no GitHub.

Fase 6 — Eval e Observability (1 semana)

LangSmith é o foco principal (tracing, datasets, evaluators, regression testing). LLM-as-judge avançado: prompts de eval, rubrics, pairwise vs. absolute scoring, calibração com anotação humana. Recursos: LangSmith docs, Eugene Yan posts, Hamel Husain "Your AI Product Needs Evals".

Fase 7 — Cloud e Deploy (2 semanas)

Docker refinement (multi-stage builds), AWS para AI (Lambda, API Gateway, S3, Bedrock basics, IAM, Secrets Manager), Modal como alternativa Python-first, Railway/Fly.io para MVPs, e GitHub Actions para CI/CD com eval como gate.

Checkpoints de revisão

- **Final da Fase 2 (Semana 5):** consegue construir chatbot com tool calling em OpenAI e Anthropic sem framework? Se não, volta.
- **Final da Fase 3 (Semana 8):** tem RAG production-grade rodando com eval automatizado? *Portão mais importante.*
- **Final da Fase 5 (Semana 11):** MCP server publicado? Não pula — é o item de maior ROI.
- **Final da Fase 7 (Semana 14):** deploya qualquer projeto em menos de 30 minutos em Lambda ou Modal? Sinal de job-ready.

6. Python para entry-level (deep dive)

"Avançado" aqui significa código que passa em code review de um mid-level sênior, não domínio de internals do CPython. Mire em entrevista entry-level de AI Engineer, não em vaga de core dev.

Must-have (sem isso não passa)

M1 — Type hints completos e modernos

Toda função tipada. Sem Any por preguiça. Sintaxe Python 3.10+.

```
# Intermediário
def search(query, top_k=5):
    return [...]

# Entry-level pronto
def search(query: str, top_k: int = 5) -> list[Document]:
    return [...]
```

Dominar: list[X], dict[K, V], X | None (no lugar de Optional[X]), Callable[[int], str], TypedDict, Protocol para duck typing tipado, Literal. Rodar mypy ou pyright no projeto.

M2 — Pydantic v2

Sem isso, AI Engineer não existe. Schemas de I/O de LLM, configuração e validação dependem de Pydantic.

```
from pydantic import BaseModel, Field

class SearchRequest(BaseModel):
    query: str = Field(min_length=1, max_length=500)
    top_k: int = Field(default=5, ge=1, le=100)
    filters: dict[str, str] | None = None
```

Dominar: BaseModel, field validators (@field_validator), model_dump(), model_validate(), Settings com pydantic-settings para env vars.

M3 — Async/await aplicado

Saber **quando** usar: I/O bound (chamadas LLM, HTTP, DB). Não para CPU bound. Dominar: async/await, asyncio.gather (paralelismo), async context managers, httpx async client.

```
import asyncio
import httpx

async def fetch_all(urls: list[str]) -> list[dict]:
    async with httpx.AsyncClient() as client:
        tasks = [client.get(url) for url in urls]
        responses = await asyncio.gather(*tasks)
        return [r.json() for r in responses]
```

M4 — Error handling profissional

Nada de except Exception: pass. Custom exceptions quando faz sentido. Exception chaining com raise X from e.

```
class RetrievalError(Exception):
    """Raised when document retrieval fails."""

try:
    embedding = await get_embedding(text)
except httpx.HTTPStatusError as e:
    raise RetrievalError(
        f"API returned {e.response.status_code}"
    ) from e
```

M5 — Pytest sólido

Dominar: fixtures, `@pytest.mark.parametrize`, `pytest-asyncio` para código assíncrono, mocking com `unittest.mock` ou `pytest-mock`, organização do diretório `tests/`.

M6 — Estrutura de projeto moderna

Em Python 2026: **uv** (não pip puro, não poetry mais) como gerenciador de deps; **pyproject.toml** como único arquivo de config; **Ruff** como linter + formatter (substitui black + flake8 + isort + pylint); **mypy** ou **pyright** como type checker; layout `src/your_package/`.

```
uv init my-rag-app
uv add fastapi pydantic openai
uv add --dev pytest ruff mypy
uv run pytest
uv run ruff check .
uv run mypy src/
```

Should-have (esperado em código de produção)

- **S1 — Logging estruturado** (não print). `structlog` para logs JSON parseáveis.
- **S2 — pathlib** em vez de `os.path`. `Path.read_text()`, `Path.glob()`, etc.
- **S3 — Dataclasses ou Pydantic** em vez de dicts soltos. Dataclass para estruturas internas; Pydantic para I/O.
- **S4 — Context managers** customizados via `@contextmanager`.
- **S5 — Generators e comprehensions** aplicados com discernimento (saber quando vira ilegível).
- **S6 — functools essencial**: `lru_cache`, `wraps`, `partial`.

Nice-to-have (diferencia em entrevista)

- **N1 — Decorators custom úteis** (retry com exponential backoff, timing, logging).
- **N2 — itertools quando cabe** (chain, groupby, islice, batched em Python 3.12+).
- **N3 — CLI moderna com typer** (mesmo autor do FastAPI, Sebastián Ramírez, mais ergonômico que `argparse`).

O que ESQUECER (red flags inversas)

Estes tópicos aparecem em cursos de "Python Avançado" mas são irrelevantes para entry-level AI Engineer. Se um curso dedica 3 aulas a eles, troque de curso.

- Metaclasses — 99% dos AI Engineers nunca usam.
- Descriptors — abstração pesada, irrelevante.
- `__slots__` — otimização raramente necessária.
- `asyncio` internals (event loops, transports) — saber usar `asyncio.gather` é o que importa.
- GIL profundo — saiba que existe, não filosofa sobre.
- Threading complexo — `async` + multiprocessing cobre 99% dos casos AI.
- C extensions, Cython, Numba — não é o mundo do AI Engineer aplicado.
- Type system avançado (variance, `TypeVar` com bounds complexos).

Self-assessment (10 perguntas)

Responda com sinceridade. Se não consegue, há gap a fechar.

1. Sabe escrever função `async` que faz 10 chamadas HTTP em paralelo e retorna resultados ordenados? (`asyncio.gather`)
2. Sabe a diferença entre `list[X]` e `tuple[X, ...]` no type hint e quando usar cada um?
3. Sabe criar `BaseModel` Pydantic com validator custom que rejeita strings vazias?

4. Sabe escrever teste pytest com fixture + parametrize?
5. Sabe a diferença entre `raise e` e `raise NewError() from e`?
6. Sabe por que `@dataclass(frozen=True)` é útil?
7. Sabe configurar projeto novo com uv init, adicionar deps e rodar ruff check?
8. Sabe explicar quando usar `@property` em vez de método convencional?
9. Consegue ler stack trace de exception chained e identificar causa raiz?
10. Sabe a diferença entre `Path("a") / "b"` e `os.path.join("a", "b")` além da sintaxe?

8 ou mais "sim": entry-level Python solid. Avança para Fase 1.2 (FastAPI).

5 a 7 "sim": 1 a 2 semanas de gap. Foca nos blocos M.

Menos de 5 "sim": investe 2 a 3 semanas antes de prosseguir.

Roteiro prático de 2 semanas (~30h)

Semana 1 (~15h): Fluent Python (Luciano Ramalho), 2ª ed. — capítulos 5 (dataclasses), 8 (type hints), 9 (decorators e closures), 19 (concorrência). Setup de projeto novo do zero com uv + ruff + mypy + pytest.

Semana 2 (~15h): Fluent Python capítulos 17 (iterators e generators) e 21 (asyncio). Refactor de um projeto pessoal (DentBot ou Pioneira) aplicando 100% type hints, ruff sem warnings, mypy sem errors, pytest cobrindo o fluxo principal e structured logging substituindo prints.

Check de domínio: o refactor da semana 2 é o gate. Bonus: rodar `mypy --strict` com zero erros.

7. Plano de 90 dias com projetos flagship

Premissas

- Budget de tempo: 15 a 20 horas por semana (~2-3h/dia úteis + fim de semana).
- Output: 3 projetos flagship + 1 servidor MCP + LinkedIn build-in-public.
- Tudo público no GitHub com README profissional em inglês.
- Linha do tempo estrita — se atrasar 1 semana, corta escopo, não estica deadline.

Visão geral dos 3 projetos

Mê s	Projeto	Foco principal
1	DevDocs RAG	RAG production-grade: FastAPI + pgvector + Cohere Rerank + LangSmith
2	Research Agent + MCP Server	Agentic com LangGraph + MCP server custom + multi-provider
3	DentBot Voice	Voice AI integrado: Whisper + ElevenLabs + AWS Lambda + WhatsApp

Os três projetos se conectam: Project 2 consome Project 1 via MCP; Project 3 também consome Project 1 e usa padrões de Project 2. Não é portfolio fragmentado — é um ecossistema coerente que demonstra arquitetura, não só features isoladas.

Projeto 1 — DevDocs RAG (Semanas 1–4)

Conceito: Q&A API sobre documentação técnica real (sugestão: docs do FastAPI). Documentação técnica é o caso mais difícil para RAG — mistura código, jargão e hierarquia.

Stack: Python 3.12 + type hints rigoroso, FastAPI com streaming SSE, PostgreSQL + pgvector via Docker, LangChain, Cohere Rerank, LangSmith, Docker + docker-compose, deploy Railway ou Fly.io.

Marcos semanais: Semana 1 — ingestion e embeddings; Semana 2 — retrieval (vector + BM25 + RRF + reranking); Semana 3 — geração + streaming + citation tracking; Semana 4 — eval (30 a 50 queries com métricas) + deploy + README com benchmarks.

Projeto 2 — Research Agent + MCP (Semanas 5–8)

Conceito: agente de pesquisa que aceita uma pergunta complexa ("analyze MCP adoption across AI frameworks Q1 2026") e produz relatório usando múltiplos MCP servers como tools, incluindo um custom (devdocs-mcp) que conecta ao Projeto 1.

Por que vale o investimento: MCP é o padrão emergente (97M downloads/mês). Quase ninguém tem servidor MCP público — diferencial bruto em CV técnico.

Stack: LangGraph (state machine plan → search → synthesize → critique → refine), MCP Python SDK, multi-provider com cost-aware routing, custom eval harness com LLM-as-judge, deploy Modal ou Railway.

Projeto 3 — DentBot Voice (Semanas 9–12)

Conceito: evolução do DentBot existente. Paciente envia áudio no WhatsApp; Whisper transcreve; agente processa com tool calling; ElevenLabs gera resposta em voz; bot retorna áudio. Integra com Projeto 1 (RAG sobre FAQs do consultório).

Por que vale: constrói sobre projeto em produção real; voice AI paga premium (US\$ 90/hora em listings Lemon.io); pode virar feature paga do DentBot SaaS.

Stack: Whisper API, ElevenLabs ou OpenAI TTS, LangGraph para conversation state, Evolution API (Pablo já domina), AWS Lambda + API Gateway, DynamoDB ou Postgres para state, LangSmith para observability. Latency budget: menor que 3s end-to-end.

Atividades paralelas (semanal)

- **Diário (~30 min):** 1 LeetCode easy/medium em Python (interview prep) + 1 newsletter (Latent Space, AI Engineer Weekly).
- **Semanal (~2h):** 1 post técnico no LinkedIn (build in public) + 5 aplicações em vagas.
- **Mensal:** pin top 6 repos no GitHub profile + atualizar CV/LinkedIn com novo projeto.

Métricas de sucesso ao final dos 90 dias

- 3 repositórios públicos com README profissional em inglês.
- Mínimo de 2 URLs de deploy vivos e demonstráveis.
- 1 MCP server publicado (diferencial raro).
- 8 a 12 posts técnicos no LinkedIn.
- 30+ vagas aplicadas em plataformas curadas.
- 3+ entrevistas técnicas realizadas.

Métricas ao Day 180 (visão de saída)

- Oferta full-time mid-level US\$ 50–80K/ano, ou
- US\$ 40+/hora freelance estável, 25h+/semana.

8. Plataformas, posicionamento e anti-padrões

Plataformas em ordem de prioridade

Plataforma	Perfil ideal	Quando usar
Lemon.io	AI Engineer com portfolio em produção	Após Semana 4 (Projeto 1 deployado)
Wellfound (ex-AngelList)	Startups que aceitam portfolio-driven	Imediato
Arc.dev	Listings n8n e AI explícitas, timezone overlap	Após Semana 6
Revelo	Best-in-class para devs brasileiros	Imediato
Upwork	Complemento freelance enquanto busca full-time	Imediato
Toptal	Top 3% global, vetting intenso	Após Semana 12 (3 projetos prontos)
Howdy / TECLA	EOR LATAM, retenção alta	Após Semana 8

Princípio: consolidar em 3 a 4 plataformas curadas. Atirar em 10 plataformas com perfil incompleto é dispersão que gera zero inbound.

Posicionamento estratégico

A narrativa que abre portas em entrevistas de AI Engineer internacional para Pablo é uma síntese de três elementos raramente combinados em um mesmo candidato:

- 1. Production AI deployment** — DentBot atende cliente real (Dental Studio, Drs. Luiz Alberto Paiva e Bianca Nóbrega) com métricas concretas de redução de tempo de atendimento.
- 2. Inglês fluente com 4 anos morando na Austrália** — comunicação técnica e cultural em ambiente multicultural já comprovada, com experiência de liderança de equipes de até 10 pessoas.
- 3. Stack moderna alinhada com mercado de 2026** — n8n, Evolution API, OpenAI, em transição estruturada para a stack AI Engineer canônica (FastAPI, LangChain, LangGraph, MCP).

O ângulo "brasileiro que morou 4 anos na Austrália e construiu AI receptionist em produção" é distintivo. Vai além do CV — vira material para um LinkedIn launch post quando Project 3 estiver no ar.

Títulos a perseguir vs. a evitar

Perseguir	Evitar
AI Automation Engineer	Senior ML Engineer (sem fine-tuning)
LLM Integration Engineer	Data Scientist (sem stats sólido)
AI Implementation Engineer	Research Engineer (exige papers/PhD)
Solutions Engineer (AI)	MLOps Engineer (exige K8s avançado)
Workflow Automation Engineer	Computer Vision Engineer
Forward-Deployed Engineer	AI Architect (5+ anos exigidos)

Anti-padrões a evitar

- **Toy projects.** 3 projetos com profundidade são melhores que 10 superficiais. Hiring manager percebe a diferença em 30 segundos lendo o README.

- **Framework worship.** Não conseguir explicar o que LangChain faz por baixo gera red flag em entrevista. Construir pelo menos uma chain manualmente sem framework para entender os primitivos.
- **"It works" sem eval.** Toda saída de LLM deve ter número associado. Sem métrica de groundedness ou relevance, é desqualificação automática.
- **Dispersão de frameworks.** LangChain + LangGraph é suficiente. Não adicionar CrewAI, AutoGen, DSPy sem razão técnica clara.
- **README ruim.** Vale tanto quanto o código. Hiring manager lê 30 segundos — se não entender o projeto, perdeu.
- **Trabalho em silêncio.** Build in public no LinkedIn gera inbound de recruiters. Recruiters buscam por keywords técnicas.
- **Esticar deadline.** Cortar escopo, não mover data. Ship algo a cada 4 semanas, não importa quão simples.
- **Atirar para todo lado.** 2 a 4 plataformas curadas, não 10 com perfil incompleto.
- **Estudar sem build.** Cada bloco do study map tem check de domínio prático. Sem o check, fase não fecha.

Tributação Brasil — heads-up rápido

A partir de 1º de janeiro de 2026 entrou em vigor a Lei 15.270/2025, que estabelece **tributação na fonte de 10% sobre lucros e dividendos** em distribuições feitas via PJ. Isso altera o cálculo clássico de "abre PJ, distribui tudo como lucro isento". Recomendação: contador especializado em PJ internacional antes de fechar o primeiro contrato em dólar.

9. Recursos permanentes (blogs, livros, cursos)

3 livros essenciais (não mais que isso)

1. **AI Engineering** — Chip Huyen (2024/2025). O livro definitivo para AI Engineer aplicado hoje.
2. **Fluent Python, 2ª ed** — Luciano Ramalho. Para Python sólido. Autor brasileiro, leitura confortável.
3. **Designing Machine Learning Systems** — Chip Huyen. Mesmo sendo ML-focused, os capítulos de deploy, monitoring e data quality se aplicam diretamente a AI Engineering.

Não comprar outros livros até terminar esses três. Acumular livros é procrastinação disfarçada de progresso.

Blogs (leitura recorrente obrigatória)

- **Hamel Husain** — hamel.dev. Evaluations, MLOps aplicado. O post "Your AI Product Needs Evals" é leitura definitiva.
- **Eugene Yan** — eugeneyan.com. Patterns para LLM systems, eval design, design choices em produção.
- **Simon Willison** — simonwillison.net. Newsletter quase diária, ferramentas LLM, builds práticos.
- **Chip Huyen** — huyenchip.com. Designing AI systems, deep dives sobre arquitetura.
- **Lilian Weng** — lilianweng.github.io. Deep dives técnicos (prompt engineering, agents, hallucinations).
- **Anthropic Engineering Blog** — anthropic.com/news. Contextual Retrieval, Computer Use, MCP — fontes primárias.

Podcasts

- **Latent Space** (Swyx) — semanal, AI Engineering puro.
- **The Cognitive Revolution** — entrevistas longas e profundas com builders.

Newsletters

- **AI Engineer** (newsletter do Swyx) — gratuita, alta densidade.
- **The Pragmatic Engineer** (Gergely Orosz) — paga, vale investimento para visão de carreira tech.

YouTube (cursos curtos gratuitos)

- **DeepLearning.AI** — short courses de 1 a 2 horas cada, todos gratuitos. "LangChain for LLM Application Development", "AI Agents in LangGraph", "Building and Evaluating Advanced RAG", "LLMOps".
- **LangChain channel** — overviews oficiais, "RAG from Scratch" series (Lance Martin).
- **Andrew Ng** — fundações e visão de mercado.

Documentação oficial (referência permanente)

- **OpenAI Cookbook** — github.com/openai/openai-cookbook.
- **Anthropic Cookbook** — github.com/anthropics/anthropic-cookbook.
- **Anthropic Prompt Engineering Tutorial** — Jupyter notebooks gratuitos, melhor recurso free sobre o tema.
- **FastAPI docs oficiais** — funcionam como tutorial completo. Não pular o passo a passo.
- **LangChain docs** — quickstart + LCEL section.
- **LangGraph docs** — tutorials section + examples repo.
- **modelcontextprotocol.io** — site oficial do MCP.

- **Cohere LLM University** — módulos gratuitos de embeddings e retrieval, excelente material.
- **Pinecone Learning Center** — pinecone.io/learn, guias avançados de RAG.
- **pgvector README** — completo e curto, no GitHub.
- **uv docs** — astral.sh/uv. Quickstart é essencial.

10. Fontes consultadas

Todas as estatísticas, faixas salariais e projeções neste relatório foram extraídas de fontes públicas consultadas entre janeiro e maio de 2026. Lista organizada por categoria:

Mercado e demanda

- **LinkedIn Jobs on the Rise 2026 Report** — ranking de 25 vagas com maior crescimento em 3 anos nos EUA.
- **World Economic Forum** — "AI has already added 1.3 million jobs, LinkedIn data says" (janeiro 2026).
- **World Economic Forum Future of Jobs Report 2025**.
- **U.S. Bureau of Labor Statistics** — projeções ocupacionais 2023-2033.
- **ManpowerGroup 2026 Talent Shortage Survey** — 39.000 empregadores em 41 países.
- **Stanford AI Index 2025** — investimento e funding em IA.
- **Gartner** — forecast de gasto global em IA 2026.
- **Menlo Ventures** — gasto empresarial em IA 2023-2025.
- **AI Workforce Consortium (Cisco)** — fastest-growing ICT roles.
- **Second Talent** — "Global AI Talent Shortage Statistics 2026".
- **CBS News / LinkedIn** — entry-level AI hiring trends (abril 2026).
- **Robert Half 2026 Salary Guide**.
- **CompTIA State of the Tech Workforce 2025**.
- **ZipRecruiter 2026 Annual Grad Report**.
- **NACE (National Association of Colleges and Employers)** — Class of 2026 hiring projections.
- **Rezi.ai** — "The Crisis of Entry-Level Labor in the Age of AI" (janeiro 2026).
- **HeroHunt** — "Fastest Growing AI Roles in 2026".
- **365 Data Science** — análise de 1.000 job postings de AI Engineer 2026.

Salários e benchmarks de remuneração

- **Howdy** — "Brazil Software Engineer Salary & Hiring Cost Benchmarks 2026" e "2026 LatAm Software Engineer Cost Benchmarks" (~12.500 desenvolvedores).
- **South Hire** — "LATAM Salary Benchmark 2026" e "How Much Does It Cost to Hire an AI Engineer in Latin America".
- **Mismo** — "LATAM Software Engineer Salary Guide 2026".
- **Lemon.io** — listings de AI Engineer com rates explícitos (maio 2026).
- **Arc.dev** — "Remote Software Developer Salary in Brazil 2026".
- **Jobicy** — "AI Engineer Salary in Brazil 2026" (fevereiro 2026).
- **Qubit Labs** — "AI Engineer Salaries in 2026: Comprehensive Guide".
- **Numerando** — salários CLT Brasil 2026.
- **Payscale** — entry-level software developer Brazil, automation engineer benchmarks.
- **ZipRecruiter** — n8n developer rates (maio 2026).
- **agentic-engineering-jobs.com** — 534 listings de agentic AI (abril 2026), análise LangChain job market.
- **Athyna** — "How to hire developers in Latin America".
- **Remote Rocketship** — junior backend e software engineer salaries em Europe.
- **RemotifyEurope** — "What Remote Software Engineers Earn Across Europe in 2026".

- **Kaptas Global** — salários Brasil para US remote teams.

Stack técnica e roadmaps

- **MockExperts** — "AI Engineer Interview Roadmap 2026: RAG & Vector DBs".
- **Let's Data Science** — "AI Engineer Roadmap 2026".
- **DataCamp** — "The 14 Essential AI Engineer Skills 2026".
- **iSmartRecruit** — "LLM Engineer Job Description: Duties & Requirements 2026".
- **Indeed** — agregados de job postings junior AI engineer.
- **TripleTen** — "AI Skills 2026: The Employer's Wishlist".
- **Morson Jobs** — "Top AI skills engineers should learn in 2026".
- **DataExpert.io** — "AI Engineering Career Path: Complete Guide for 2026".
- **HR Oasis** — "Latin America Developer Salaries 2026: Complete Compensation Guide".

Plataformas de contratação avaliadas

- **DistantJob** — "Best Sites to Hire Remote Developers in 2026".
- **Wild.Codes** — "Best Platforms to Hire Remote Developers in 2026".
- **Revelo** — "How to Hire Software Developers Based in Brazil in 2026: Salary Guide".
- **Jobgether** — "Remote Jobs in Brazil".
- **Himalayas** — remote salaries Brazil, n8n companies.
- **Anthropic / Linux Foundation** — MCP protocol documentation e adoption statistics.

Este relatório foi gerado a partir de pesquisa em fontes públicas. As faixas salariais e estatísticas variam por fonte e momento da coleta; tratá-las como ordens de grandeza, não como valores precisos. Mercado de IA muda rápido — revisar a cada 3 a 6 meses.